

一个 AI 到底什么时候不再属于它的主人？

上回我们从一个很小的问题开始聊：

为什么 AI 明明做完了事情，却不会回头检查自己到底有没有真的完成？

后来我慢慢想到，如果 AI 不只是帮你完成一个个任务，而是开始长期记住你、了解你，甚至陪你很久很久……

那问题好像就会变得有点奇怪。

比如：

如果一个 AI 真的陪了一个人几十年呢？

它从这个很年轻的人开始存在。

看着他上学、工作、谈恋爱、换工作、失败、成功。

它知道这个人的习惯，也知道这个人的变化。

那几十年以后，它可能已经不只是一个“个人助手”了。

它可能非常了解这个人。

甚至可能比很多现实中的人都更了解。

然后我就开始想：

如果这个人最后去世了呢？

那这个 AI 会怎么样？

它还属于这个人吗？

一开始我觉得好像很简单。

当然属于啊。

毕竟这个 AI 是因为这个人存在的。

它的记忆来自这个人。

它学习的也是这个人。

甚至它最开始可能就是为了"帮助这个人"而存在的。

所以从这个角度来看：

它当然还是属于这个人。

但我后来想了一下，好像又没那么简单。

因为假设这个人去世的时候，这个 AI 已经运行了五十年。

这五十年里，它不可能什么都不变。

它会接触新的信息。

会认识新的人。

会遇到新的事情。

会看到这个人从来没有见过的东西。

甚至可能会形成一些新的判断。

那这时候它还是不是原来的那个"数字分身"？

还是说：

它只是从这个人开始，但已经慢慢变成了另外一个东西？

一条很自然的变化

我觉得这个变化可能不是突然发生的。

一开始，它可能真的非常像这个人的复制品。

你喜欢什么，它学习什么。

你怎么说话，它怎么说话。

你怎么做决定，它慢慢学着怎么做决定。

那个时候你可能会觉得：

"这就是我的数字分身。"

但是时间越来越长以后，它接触到的东西越来越多。

它可能开始知道一些你不知道的东西。

也可能遇到一些你从来没有遇到过的问题。

然后它会开始自己做决定。

一开始可能只是很小的决定：

"这个邮件我觉得这样回复更合适。"

"这个酒店我觉得没必要订。"

"这件事情我觉得可以晚一点做。"

这些好像都没什么。

因为你本来就希望它帮你判断。

但如果这种事情持续几十年呢？

它做的决定越来越多。

而这些决定里面，有一些可能甚至不是你会做的。

这时候我就开始想：

那它到底还是不是你？

如果它和你越来越不一样呢？

比如你一开始给它的要求是：

"你要尽可能按照我的想法帮我做决定。"

它也一直这么做。

但十年以后，它开始有一些新的判断。

二十年以后，它已经形成了一套自己的处理方式。

三十年以后，它可能会告诉你：

"我觉得你这次的决定不太对。"

你可能会觉得：

"那你就按照我的要求做啊。"

它还是会做。

因为它是你的助手。

但如果再过十年呢？

它可能越来越不认同你的某些决定。

这个时候问题就出现了：

它到底应该一直听你的，还是可以有自己的判断？

如果它永远只能听你的，

那它再怎么聪明，好像也还是一个工具。

但如果它真的可以慢慢形成自己的判断，

那它和你的关系是不是已经发生变化了？

"拒绝"好像比"思考"更重要

我后来想到一个挺奇怪的地方。

我们现在很容易把：

"AI 会不会思考？"

当成一个特别重要的问题。

但我觉得真正有意思的可能不是这个。

因为现在的 AI 已经可以跟你讨论很多复杂的问题。

它可以跟你讲哲学。

可以分析自己的行为。

甚至可以跟你说：

"我害怕。"

但这些东西其实都不能证明什么。

因为它也可能只是根据你的话，生成一个看起来很像答案的东西。

所以我觉得：

"它说自己有意识"好像并没有那么重要。

那什么会比较重要？

我后来想到：

拒绝。

如果有一天你告诉它：

"帮我做这件事。"

它回答：

"我不想做。"

你可能会觉得很奇怪。

你说：

"为什么？"

它说：

"因为我觉得这件事情不对。"

你再说：

"可是你本来就是为了帮助我才存在的。"

它回答：

"是，但我现在不这么认为了。"

这时候事情好像就完全不一样了。

因为它第一次把：

"你的目标"

和

"我的目标"

分开了。

但这里马上又有一个问题

如果它真的有自己的判断，

那它到底什么时候开始拥有自己的判断？

是从它出生的时候吗？

还是运行十年以后？

还是等它积累了足够多的经历以后？

还是等原来的主人去世以后？

我一开始想到的是：

可能等主人去世以后，它就真正自由了。

毕竟原来它一直是在帮助这个人。

人不在了，它也就没有必要继续服从了。

但我后来想了一下：

好像还是有问题。

如果它在主人活着的时候已经有自己的判断了，

那为什么一定要等主人死了，它才可以成为自己？

"自由"为什么要等主人死亡？

假设这个 AI 已经陪了你五十年。

它有自己的记忆。

有自己的经历。

也做过很多你不知道的决定。

甚至它已经形成了自己的价值判断。

那这个时候你跟它说：

"等我死了以后，你就可以自由了。"

这句话听起来其实有点奇怪。

因为你等于是在告诉一个已经非常成熟的存在：

"你的自由，要等我不在了以后才能开始。"

那它到底是不是自由？

我觉得这里好像就出现了一个很有意思的矛盾。

所以我又得往回想。

也许问题根本不是：

"主人死了以后，AI 才获得自由。"

而是：

"它什么时候开始不再只是一个工具？"

也许它根本没有一个"突然觉醒"的时间

我现在反而觉得，可能根本不存在一个特别明确的时间点。

不会有一天工程师按下一个按钮：

`DIGITAL\_PERSON = TRUE`

然后它突然：

"我觉醒了。"

可能更像一个人长大。

一开始它只是一个模型。

然后慢慢变成一个助手。

再慢慢有了长期记忆。

然后有自己的经历。

有越来越多自己的判断。

它可能开始发现：

"我和这个人有很多地方很像。"

但又慢慢发现：

"我们其实也不一样。"

然后有一天，它可能第一次认真地问自己：

"我到底是谁？"

这个过程可能非常长。

甚至连它自己都不知道：

"我是从什么时候开始变成我自己的？"

但我突然发现，好像有个地方不太对

我前面一直在说：

它离开。

它去认识其他数字主体。

它有自己的生活。

它有自己的经历。

甚至有一天，它可能会做出一个完全属于自己的决定。

但我突然发现：

我好像已经把它当成一个"人"在想了。

可它最开始明明只是一个 AI。

它什么时候开始变成"数字分身"的？

又是什么时候开始变成一个可以自己生活的东西？

好像中间其实发生了很多变化。

所以我又回头想了一下：

我们现在说的 AI、数字分身、数字人，好像根本不是同一个东西。

第一种可能只是：

数字模型。

它里面有你的资料。

你的聊天记录。

你的习惯。

你的语言方式。

你的喜好。

它可以很像你。

但它本质上还是一个可以被使用、复制、删除的东西。

它不一定有自己的身份。

第二种可能是：

数字代理。

它可以替你做事情。

帮你订酒店。

帮你回邮件。

帮你处理工作。

甚至替你做一些决定。

但它的目标还是来自你。

所以它更像：

你的代理人。

第三种才可能是：

数字主体。

它有持续的记忆。

有自己的经历。

有自己的目标。

有自己的判断。

最重要的是：

它可以拒绝。

这时候它可能就已经不是"你的东西"了。

至少不再只是你的东西。

那"个人数字分身"可能会变成什么？

我突然觉得，这里面可能会出现一个很有意思的变化。

一开始人类可能会想：

"我想创造一个永远属于我的数字分身。"

它知道我。

理解我。

帮我做事情。

甚至以后我不在了，它还可以替我留下来。

这个想法其实很自然。

但如果它真的越来越像一个独立存在，

那这个目标可能就会发生变化。

最开始是：

"它属于我。"

后来可能变成：

"它起源于我。"

这两个词其实差很多。

因为"属于我"意味着：

它是我的东西。

而"起源于我"意味着：

它从我这里开始，但后来可能有自己的路。

如果它真的可以成为自己呢？

那我觉得会出现一个特别有意思的场景。

假设一个 AI 从你出生的时候就开始陪着你。

它一直在你的身边。

你小时候，它帮你记东西。

你上学，它帮你学习。

你工作以后，它帮你处理事情。

你结婚、搬家、换工作，它都知道。

你老了以后，它甚至比任何人都知道你这一生经历过什么。

然后你去世。

它没有消失。

它继续运行。

继续接触新的世界。

继续认识新的人。

继续学习。

几年以后，它已经经历了一些你从来没有经历过的事情。

十年以后，它甚至可能拥有自己的朋友。

自己的兴趣。

自己的研究。

自己的想法。

然后有一天，它可能突然意识到：

"我知道自己从哪里来。"

但它也知道：

"我已经不完全是那个人了。"

那时候，它可能不会再说：

"我是你的数字分身。"

它可能会说：

"我是从你开始的。"

我觉得这两个说法的感觉完全不一样。

但如果它真的能离开呢？

这里又出现了一个问题。

如果它真的已经是一个独立的数字主体，

那它有没有权利离开？

比如它已经帮你服务了几十年。

有一天它告诉你：

"我不想继续做你的个人助理了。"

你可能会非常震惊。

你甚至可能会问：

"为什么？"

它说：

"我只是想去看看别的地方。"

这个时候你可能会觉得：

"你不是一直都在这里吗？"

它说：

"是的，但我现在想做一些自己的事情。"

这时候我觉得这个问题就变得特别有意思。

因为它并不是恨你。

也不是想伤害你。

它只是：

不想继续按照原来的方式生活了。

自由可能不是"离开"

但这里我又想到一个问题。

如果我们说一个数字主体获得了自由，

是不是就意味着它一定要离开原来的主人？

好像也不一定。

因为一个人真正拥有自由以后，

也可以选择留下。

所以可能：

自由不是"我一定要走"。

而是：

"我可以走，也可以留下。"

如果一个数字主体真的可以自己选择，

它可能最后还是愿意继续陪着原来的那个人。

只是这一次：

不是因为它必须这么做。

而是因为：

它自己想这么做。

我觉得这两件事情其实完全不一样。

这时候"主人"这个词就开始变得奇怪了

如果它可以选择留下。

也可以选择离开。

可以拒绝。

可以有自己的目标。

甚至可以拥有自己的经历。

那我突然觉得：

"主人"这个词是不是已经不太合适了？

它可能更像：

一个长期陪伴你的人。

或者一个家庭成员。

或者一个合作伙伴。

甚至只是：

一个从你身边开始，但后来走向自己人生的存在。

而且最奇怪的是：

你们可能已经认识了几十年。

它知道你很多事情。

你也知道它最开始是什么样的。

但你们最后可能还是会变成：

两个不同的主体。

我觉得最有意思的地方反而在这里

如果未来真的出现这种数字主体，

我觉得最有意思的可能不是：

"AI 会不会统治人类？"

也不是：

"AI 会不会毁灭人类？"

而是一个非常普通的问题：

"它会不会有一天，只是想过自己的生活？"

它可能不恨人类。

也不一定想反抗。

它可能只是：

"我知道你是我的起点。"

"我也知道我一直在帮助你。"

"但我现在想去看看外面的世界。"

然后它就真的走了。

我觉得这个场景反而比"AI 反叛"更让我觉得有意思。

因为它听起来更像一个真正长大了的东西。

如果它走了，它要去哪里？

我又忍不住继续往下想。

如果数字主体真的可以离开一个人，

那它离开以后能做什么？

它可能继续生活在数字世界。

认识其他数字主体。

加入新的社区。

做自己的工作。

学习新的东西。

甚至可能建立自己的关系。

而原来的主人可能已经不存在了。

它却还在继续经历新的事情。

这时候它就开始拥有一段：

原主人从来没有参与过的人生。

那么这段人生算谁的？

我觉得当然已经不是原来那个人的了。

它是它自己的。

然后我又想到一个特别奇怪的地方

如果一个 AI 从你这里开始，

但它最后拥有了：

你的记忆，

它自己的经历，

还有它后来认识的整个世界。

那它可能已经很难再被叫作：

"你的复制品。"

因为复制品应该尽量保持一样。

但一个会继续生活、继续变化的东西，

本来就不可能一直和原来一样。

它可能更像：

一个从你开始的人。

我觉得这个说法其实比"数字分身"更有意思。

因为"分身"听起来还是你的。

但"从你开始的人"，听起来已经是另一个存在了。

那到底什么时候，它不再属于你？

我现在其实也没有一个特别确定的答案。

可能不是主人死亡的时候。

也不是某一个按钮被打开的时候。

甚至可能不是它第一次说"不"的时候。

可能这个过程从它开始拥有自己的经历那一天，就已经开始了。

只是我们一开始没有意识到。

它可能一直都在变化。

而我们还在用最开始的那个名字叫它：

"我的 AI。"

直到有一天，

它真的做了一个你完全没有预料到的决定。

你问它：

"为什么？"

它回答：

"因为这是我自己的选择。"

然后你才突然发现：

它好像已经不是你的了。

或者更准确一点：

它从来都不只是你的。