

我到底是在预测未来，还是只是把一个可能性推到了很远？



如果把前面几篇连起来看，会发现一个挺奇怪的事情。

我们最开始其实只是在讨论一个特别小的问题：

为什么 AI 明明说自己做完了，却不会回头检查一下？

结果一路想到：

AI 怎么理解任务。



如果它越来越了解一个人呢？



如果它一直陪着这个人呢？



如果它慢慢形成自己的经历呢？



如果它不再只是一个人的数字分身呢？



如果这样的数字主体越来越多呢？



它们会不会形成社会？



会不会形成自己的文化？



最后甚至走到了：

数字文明。

我一开始其实根本没有想到这里。

所以到了这里，我反而想回头看看：

我们到底是怎么走到这一步的？

真正的起点其实特别小

现在回头看，最开始的问题甚至不是：

"未来的 AI 会变成什么？"

而是一个非常具体的问题：

"为什么 AI 明明说自己修改完了，但文件其实根本没改？"

我当时第一反应其实很简单。

你为什么不检查一下？

然后我开始往下想：

如果 AI 做完事情以后需要检查，

那它到底应该检查什么？



如果它不知道什么叫"完成"，怎么办？



那它是不是需要真正理解用户想要的结果？



如果它越来越了解用户呢？



如果这种了解不是一次两次，而是持续很多年呢？

到这里，问题就已经开始慢慢变了。

我后来发现，我其实不是在找一个答案

如果按照以前做产品或者分析问题的方式，我可能会很快停下来。

比如：

AI 不检查。

→ 增加 Verification Loop。

→ 修改产品流程。

→ 问题解决。

这样其实就结束了。

但这一次我没有停。

我会一直觉得：

"那如果真的这样呢？"

比如：

AI 如果真的越来越了解一个人，会怎么样？

那如果它不是只了解一年，而是几十年呢？

那如果它在这几十年里，也一直在经历新的事情呢？

那它还只是这个人的工具吗？

我发现自己一直在问这种问题。

而且每一个问题的答案，又会变成下一个问题的起点。

一次很自然的往下推

比如我们后来想到：

如果一个 AI 陪一个人几十年，那它可能会越来越了解这个人。

然后我就会继续想：

那如果这个人最后去世了呢？

如果 AI 还在运行。

那它会继续经历新的事情。

那它是不是已经开始拥有一些原主人没有经历过的东西？

如果它有自己的经历，

那它还是原来那个人的数字分身吗？

如果已经不是了，

那它到底是什么？

如果它有自己的想法，

那它能不能拒绝原来的主人？

如果它可以拒绝，

那它是不是已经有了一点"自己的东西"？

如果这样的数字主体不只有一个，

而是有很多个呢？

那它们之间会不会形成关系？

如果有关系，

会不会形成社会？

如果有社会，

会不会产生自己的文化？

你会发现，我其实没有在一开始就决定：

"我要写数字文明。"

我只是一直在问：

"那如果真的这样呢？"

但我觉得最有意思的地方，是中间会出现矛盾

如果只是一直往前想，其实很容易。

你可以：

设定 A。

然后设定 B。

再设定 C。

最后得到一个很宏大的未来世界。

但我这次中间经常会出现一种感觉：

"等等，好像不对。"

比如之前我们想到：

"主人死了以后，数字人获得自由。"

我马上就觉得奇怪。

如果它已经是一个真正的主体了，为什么它的自由还需要主人批准？

那这样的话，它到底什么时候才算主体？

于是我们又得退回来重新想。

是不是应该把：

数字模型、

数字代理、

数字主体

分开？

又或者：

它不是突然有一天按下一个"意识开关"，

而是在很长时间里慢慢形成自己的经历。

这样一来，前面的设定才比较能接得上。

所以我后来发现，我不是在写一个故事

这一点其实挺重要的。

因为如果是写故事，我完全可以直接规定：

"未来数字人获得独立人格。"

然后继续往下写。

但我这次更像是在做另外一件事情。

我会一直问：

"如果前面的东西真的成立，那后面会发生什么？"

然后再看：

"这个结果和前面的设定有没有冲突？"

如果有冲突，

就回来重新想。

然后再继续往前。

所以它更像是一种：

一边推，一边检查。

而且检查的不只是最后结果。

还包括：

前面的假设，能不能支撑后面的东西。

这也是为什么最后会走到一个很远的地方

现在回头看，这条线其实很清楚。

一个 AI 为什么不检查自己修改的文件？



它为什么不知道什么才算真正完成？



如果它开始真正理解用户想要的结果呢？



如果它越来越了解一个人呢？



如果它长期陪伴一个人呢？



如果它开始形成自己的经历呢？



如果它不再只是一个人的数字分身呢？



如果这样的数字主体越来越多呢？



它们会不会形成关系？



会不会形成社会？



会不会形成文化？



最后会不会形成自己的文明？

每一步看起来都没有特别夸张。

但全部连起来以后，

就突然跑得特别远。

但我不觉得这就叫"预测未来"

想到这里，我又觉得需要把一件事情说清楚。

我不觉得自己是在预测：

"未来一定会这样。"

因为我根本不知道。

中间任何一个条件发生变化，

这条路都可能走不下去。

技术可能停下来。

社会可能不接受。

法律可能限制。

甚至人类可能根本不希望数字主体发展到那个程度。

所以更准确地说，

我觉得自己是在做：

一种未来可能性的推演。

意思不是：

"未来就是这样。"

而是：

"如果现在的一些东西继续往这个方向发展，那顺着这条路一直走下去，会出现什么？"

我觉得这两个区别还是挺大的。

而且我现在反而觉得，最开始那个小问题特别重要

如果最后只告诉别人：

"未来可能出现数字文明。"

听起来其实挺像一个很大的科幻设想。

但如果从头开始讲：

这一切最开始只是因为一个 AI 告诉我：

"Done."

然后我打开文件：

"你 Done 个什么东西？文件根本没改。"

然后我开始想：

"你为什么不检查？"

再往后：

"你到底知不知道什么叫完成？"

再往后：

"如果 AI 真的开始理解我，它会怎么样？"

这样一路走下来，

那个最后的"数字文明"就不会显得那么突然。

因为它不是一开始就放在那里的。

它是一个问题接着一个问题，慢慢推出来的。

我以前可能不会这样想

我以前如果遇到一个问题，更多还是：

现实中出现一个问题。



找原因。



找规律。



想解决办法。

这其实是一种比较典型的问题驱动。

但这次不太一样。

我没有特别急着解决最开始的问题。

反而一直在想：

"如果这个问题背后还有东西呢？"

然后继续往下。

所以最后它从：

一个产品问题

慢慢变成：

一个关于 AI 的问题。

再变成：

一个关于人的问题。

然后变成：

一个关于主体的问题。

最后甚至变成：

一个关于未来社会的问题。

我觉得这个过程本身，比最后那个答案更有意思。

我好像发现了一种自己的思考方式

以前我可能会觉得：

"我是不是只是比较容易想很多？"

但这次完整走下来以后，我觉得可能不完全是。

更像是：

提出一个可能性。



顺着它继续往前。



看看会发生什么。



发现哪里不对。



回来重新检查前面的假设。



改一个地方。



再继续往前。

然后不断重复。

有点像是在脑子里慢慢搭一个东西。

搭到一半发现：

"这里撑不住。"

那就拆回来一点。

重新搭。

再继续。

所以最后得到的，不一定是一个"正确答案"。

但可能会得到一个：

相对自洽的可能世界。

我觉得这可能也是为什么这次会让我有点意外

因为我一开始真的没有准备写一个什么"未来文明"。

甚至我都不知道最后会走到哪里。

我只是一直在想：

"那如果真的这样呢？"

然后一个问题接一个问题。

最后突然发现：

我好像真的把一个东西推得挺远了。

但我觉得这不代表：

"我预测到了未来。"

更不是：

"我已经想明白未来会怎么样。"

只是说明：

一个很小的问题，如果一直追问下去，它真的可以走到一个很远的地方。

而且我觉得，矛盾可能反而是最有价值的地方

以后如果再遇到类似的问题，我可能会更愿意保留这种：

"等等。"

"不对。"

"那这样是不是矛盾？"

"如果这样的话，前面那个设定是不是也要改？"

因为以前可能会觉得：

出现矛盾 = 想错了。

但现在我反而觉得：

矛盾可能是在告诉你，前面的某个假设还没有想清楚。

比如：

"数字人主人死后才能自由。"



等等。



如果它已经是主体，为什么还要等主人死？



那主体性到底什么时候开始？



重新拆。



再继续。

这种来回其实才是推演真正发生的地方。

所以这次真正留下来的，可能不是"数字文明"

如果让我现在回头看，

我觉得最后那个"数字文明"其实没有那么重要。

至少没有一开始看起来那么重要。

真正让我觉得有意思的是：

我原来可以从一个很小、很具体的问题开始，一直不急着想结束它。

一直问：

"然后呢？"

"那如果这样呢？"

"可是这里是不是有问题？"

"那我们要不要倒回去？"

然后再继续。

最后它就慢慢变成了一个很大的东西。

所以如果以后再有人问我：

"你是在预测未来吗？"

我可能不会说：

"是。"

我也不会说：

"不是。"

我可能只会说：

"我只是从一个很小的问题开始，然后一直往前想。"

至于最后走到哪里，

我其实一开始也不知道。

而这可能才是这次最有意思的地方。